

PROJECT DESIGN

Programa: Máster Ingeniería de Datos

Nº Grupo proyecto: 3

Nombre de los miembros del equipo:

Elena Calcerrada Quiles

Joaquin Ayllon Moreno

Laura Rodriguez Mora

Miguel Angel Vicente Vicente

Rubén Martínez Sierra

PROPUESTA DE IDEAS



Nuevos y modernos trenes...

1. NOMBRE PROPUESTA SELECCIONADA: Raillytics Light — Plataforma de Ingeniería de Datos para Análisis y Predicción de Demanda Ferroviaria en España

PROBLEMA/OPORTUNIDAD	SOLUCIÓN	FUENTES DE DATOS	CLIENTES/GRUPOS DE INTERÉS	ACTIVIDADES CLAVE
Renfe y ADIF carecen de plataforma integrada para analizar datos ferroviarios públicos de forma centralizada. Los datos de viajeros, puntualidad, meteorología y festivos están dispersos y sin explotación analítica sistemática. No existe capacidad predictiva de demanda que apoye decisiones de planificación operativa.	Raillytics Light es una plataforma de ingeniería de datos end-to-end que integra, procesa y analiza datos ferroviarios públicos para generar insights operativos y predicciones de demanda. Stack 100% del máster: PySpark + dbt + Delta Lake + Snowflake + Scikit-learn + Power BI.	• Renfe Open Data: viajeros, puntualidad, servicios. • AEMET API: meteorología diaria. • Festivos BOE: calendario oficial. • INE: movilidad y población.	• Renfe y operadores ferroviarios. • ADIF: gestión de infraestructuras. • Ministerio de Transportes. • Viajeros y usuarios del servicio. • Investigadores del sector transporte.	• Ingesta batch automatizada. • Arquitectura Medallion Bronze→Gold. • Transformaciones Silver→Gold con dbt. • Carga Gold en Snowflake. • Modelo predictivo Scikit-learn. • Dashboards Power BI. • Documentación y defensa TFM.
		TIPO DE ANÁLISIS	KPIs	RECURSOS CLAVE
		• Descriptivo: viajeros históricos, puntualidad por línea, impacto de festivos. • Predictivo: predicción de demanda (Scikit-learn), correlación meteorología-puntualidad. • Prescriptivo: alertas de picos de demanda.	• Completitud de datos (%) • Latencia del pipeline • RMSE del modelo predictivo • Precisión puntualidad (F1) • N° dashboards activos • Reducción incidencias (%)	• PySpark (procesamiento) • dbt (Silver→Gold) • Delta Lake + Parquet • Snowflake (Gold / DWH) • Scikit-learn (ML) • Power BI (visualización) • GitHub (versiones) • Python (ingesta)
COSTE DE IMPLEMENTACIÓN	RIESGOS	BENEFICIOS/IMPACTOS		
Coste TFM: 0 € (todas las herramientas gratuitas o con trial) Producción estimada: 800 - 2.000 €/mes	• Calidad irregular de Renfe Open Data. • Límite trial Snowflake 30 días. • Precisión del modelo predictivo. • Alcance ajustado a 5 personas y 4 meses. • Curva aprendizaje dbt/Snowflake.	• Stack tecnológico completo y profesional demostrable ante el tribunal. • Datos públicos disponibles desde el día 1. • Demuestra las 3 áreas del máster equilibradas. • Base escalable para futuras ampliaciones. • Perfil laboral reforzado en Data Engineering.		

2. NOMBRE PROPUESTA 1: Railytics — Plataforma de Ingeniería de Datos para el Análisis y Predicción de Demanda Ferroviaria en España

PROBLEMA/OPORTUNIDAD	SOLUCIÓN	FUENTES DE DATOS	CLIENTES/GRUPOS DE INTERÉS	ACTIVIDADES CLAVE
Datos de Renfe dispersos e infrautilizados sin pipeline moderno de integración. Ausencia de analítica avanzada sobre puntualidad y demanda ferroviaria en España.	Plataforma completa de ingeniería de datos con arquitectura Lakehouse, pipelines batch y streaming, modelos predictivos y dashboards ejecutivos.	• Renfe Open Data • INE: población y movilidad • AEMET: meteorología • Festivos nacionales y autonómicos • Google Mobility (opcional)	• Renfe y operadores ferroviarios • ADIF • Ministerio de Transportes • Investigadores del sector transporte	• Pipelines de ingesta automatizados • Arquitectura Lakehouse completa • Pipelines batch y streaming (Kafka) • Modelos predictivos múltiples • Dashboards ejecutivos Power BI
		TIPO DE ANÁLISIS	KPIs	RECURSOS CLAVE
		• Descriptivo: demanda histórica, puntualidad por línea. • Predictivo: Prophet, ARIMA, Random Forest, XGBoost. • Prescriptivo: alertas de picos y recomendaciones de ajuste de frecuencias.	• Completitud de datos (%) • Precisión del modelo (RMSE) • Latencia del pipeline • F1-score puntualidad • Nº dashboards activos	• PySpark (batch + streaming) • Kafka (tiempo real) • Delta Lake + Parquet • Airflow (orquestración) • Power BI • GitHub
COSTE DE IMPLEMENTACIÓN	RIESGOS	BENEFICIOS/IMPACTOS		
Desarrollo y mantenimiento de la plataforma completa: 90.000 – 140.000 €/año en producción. Infraestructura cloud: 12.000 – 30.000 €/año.	• Calidad irregular de Renfe Open Data. • Complejidad de integración de fuentes heterogéneas. • Limitación de precisión en modelos predictivos. • Escalabilidad de infraestructura cloud.	• Mejora de la puntualidad ferroviaria mediante predicción temprana. • Optimización de recursos y planificación de servicios. • Plataforma escalable y reutilizable para otros operadores.		

3. NOMBRE PROPUESTA 2: Enerlytics — Plataforma de Ingeniería de Datos para Optimización del Consumo Energético en Infraestructuras Críticas

PROBLEMA/OPORTUNIDAD	SOLUCIÓN	FUENTES DE DATOS	CLIENTES/GRUPOS DE INTERÉS	ACTIVIDADES CLAVE
Infraestructuras críticas (CPDs, estaciones) consumen grandes cantidades de energía con datos dispersos y sin integración ni analítica avanzada. Gestión reactiva sin capacidad de predicción de demanda energética ni detección de ineficiencias.	Plataforma de ingeniería de datos que permite monitorizar, analizar y optimizar el consumo energético en entornos industriales y CPDs mediante IoT + Spark + ML.	• Sensores IoT (temperatura, consumo, humedad) • SCADA / BMS • AEMET: meteorología • Tarifas eléctricas • Calendario laboral	• Operadores de CPDs • Gestores de infraestructuras ferroviarias (ADIF) • Responsables de sostenibilidad y ESG • Directores financieros	• Ingesta IoT en tiempo real (Kafka + MQTT) • Pipeline batch y streaming con Spark • Lakehouse energético (Bronze/Silver/Gold) • Modelo predictivo de consumo • Sistema de alertas en tiempo real
		TIPO DE ANÁLISIS	KPIs	RECURSOS CLAVE
		• Descriptivo: consumo por instalación, franja horaria. • Predictivo: predicción de demanda energética (Prophet/XGBoost). • Prescriptivo: alertas ante consumos anómalos, recomendaciones de desplazamiento de cargas.	• Latencia del pipeline IoT • Reducción del consumo (%) • Ahorro en costes energéticos (€/año) • Tasa de detección de anomalías • Reducción huella de carbono	• Apache Kafka + MQTT (IoT) • PySpark (batch + streaming) • Delta Lake + Parquet • Snowflake (Gold) • Prophet / XGBoost • Power BI
COSTE DE IMPLEMENTACIÓN	RIESGOS	BENEFICIOS/IMPACTOS		
Personal + infraestructura cloud e IoT: 133.000 – 230.000 €/año en producción. Coste TFM: 0 € (herramientas gratuitas y trial).	• Fiabilidad de sensores IoT (fallos hardware). • Integración con sistemas legacy SCADA/BMS. • Precisión de modelos ante factores no modelados. • Escalabilidad ante múltiples instalaciones.	• Reducción de costes energéticos mediante optimización del consumo. • Monitorización en tiempo real desde un único dashboard. • Reducción de la huella de carbono y alineación con objetivos ESG.		


4. NOMBRE PROPUESTA 3: Maintenanclytics — Plataforma de Ingeniería de Datos para Mantenimiento Predictivo en Sistemas Críticos

PROBLEMA/OPORTUNIDAD	SOLUCIÓN	FUENTES DE DATOS	CLIENTES/GRUPOS DE INTERÉS	ACTIVIDADES CLAVE
Sistemas críticos (trenes, CPDs, UPS) gestionados con mantenimiento reactivo y sin capacidad de predicción de fallos ni estimación de vida útil de componentes. Datos operativos (logs, sensores, tickets) sin explotar analíticamente.	Plataforma end-to-end de Data Engineering + Predictive Analytics para mantenimiento predictivo de sistemas críticos. Detecta patrones de fallo y predice averías antes de que ocurran.	• Logs de sistemas (servidores, redes) • Sensores: temperatura, voltaje, CPU • Tickets de incidencias (Remedy/ITSM) • Historial de mantenimiento • Condiciones ambientales (AEMET)	• Equipos IT y Operaciones de grandes organizaciones • Operadores ferroviarios (Renfe/ADIF) • Gestores de CPDs • Directores de Operaciones (COO)	• Pipeline de ingesta de logs en tiempo real (Kafka) • Feature Engineering industrial (rolling windows) • Modelos de predicción de fallos y RUL • Pipeline inferencia streaming • Dashboards operativos de mantenimiento
		TIPO DE ANÁLISIS	KPIs	RECURSOS CLAVE
		• Descriptivo: MTBF, MTTR, incidencias por componente. • Predictivo: predicción de fallos (XGBoost), Remaining Useful Life (RUL). • Prescriptivo: alertas predictivas, programación óptima de mantenimiento.	• F1-score predicción de fallos • Tasa de falsos positivos • Tiempo de anticipación de fallos • MTBF / MTTR • Reducción incidencias (%)	• Apache Kafka (logs en tiempo real) • PySpark (batch + streaming) • Delta Lake + Parquet • Snowflake (Gold) • XGBoost / Random Forest • Power BI
COSTE DE IMPLEMENTACIÓN	RIESGOS	BENEFICIOS/IMPACTOS		
Personal + infraestructura cloud: 140.000 – 240.000 €/año en producción. Coste TFM: 0 € (herramientas gratuitas y trial).	• Calidad de datos de logs (incompletos o no estructurados). • Alta tasa de falsos positivos puede reducir confianza operativa. • Dependencia de datos históricos para entrenamiento. • Resistencia del equipo operativo a herramientas predictivas.	• Transformación del mantenimiento: de reactivo a predictivo. • Reducción estimada del 20-30% en incidencias no planificadas. • Optimización del inventario de repuestos basada en RUL.		

5. DESCRIPCIÓN DE PROPUESTA SELECCIONADA:

PROPUESTA SECCIONADA:

**Raillytics Light — Plataforma de Ingeniería de Datos
para Análisis y Predicción de Demanda Ferroviaria en España**



1. PROBLEMA / OPORTUNIDAD

PROBLEMA / OPORTUNIDAD

Descripción del Problema:

España cuenta con una extensa red ferroviaria que genera diariamente millones de datos sobre viajeros, puntualidad, servicios y estaciones. A pesar de la disponibilidad pública de parte de estos datos a través de Renfe Open Data, no existe una plataforma integrada que los consolide, procese y explote analíticamente de forma sistemática.

Los principales desafíos identificados son:

1. Fragmentación e infrautilización de los datos públicos ferroviarios:

Los datos de Renfe Open Data, AEMET, INE y el calendario de festivos existen por separado y en formatos heterogéneos. No hay ningún sistema que los integre en un pipeline automatizado que permita obtener una visión consolidada de la demanda ferroviaria y sus factores de influencia.

2. Ausencia de analítica predictiva operativa:

No existe una herramienta que permita predecir la demanda de viajeros por línea o estación con antelación suficiente para optimizar la asignación de recursos. Las decisiones se toman principalmente de forma reactiva o basándose en series históricas simples.

3. Falta de visibilidad ejecutiva sobre KPIs ferroviarios:

No hay dashboards interactivos accesibles que permitan monitorizar en tiempo near-real-time la evolución de la demanda, la puntualidad por línea y el impacto de factores externos como la meteorología o los festivos.

Implicaciones y Necesidad del Problema:

La ausencia de una plataforma de datos ferroviarios integrada limita la capacidad de planificación operativa de Renfe y ADIF, incrementa los costes por mala asignación de recursos y reduce la calidad del servicio al viajero. En un contexto en el que la sostenibilidad del transporte público es prioritaria, existe una necesidad real de explotar los datos ya disponibles para tomar decisiones más inteligentes y eficientes.

2. SOLUCIÓN

SOLUCIÓN

Descripción de la Solución:

Raillytics Light es una plataforma de ingeniería de datos end-to-end que integra, procesa y analiza datos ferroviarios públicos para generar insights operativos y predicciones de demanda.

Componentes Clave de la Solución:

1. Pipeline de Ingesta Automatizado (Python):

Scripts Python que descargan y validan automáticamente los datasets de Renfe Open Data, la API de AEMET y el calendario de festividades del BOE. Los datos en bruto se almacenan en la capa Bronze en formato Parquet/Delta Lake.

2. Arquitectura Medallion (Bronze → Silver → Gold):

Procesamiento por capas con PySpark para Bronze→Silver (limpieza, normalización, enriquecimiento) y dbt para Silver→Gold (modelo dimensional). La capa Gold se carga en Snowflake para consultas analíticas eficientes.

3. Modelo Predictivo de Demanda (Scikit-learn):

Modelo de regresión entrenado con datos históricos de viajeros, enriquecido con variables de meteorología, festividades y estacionalidad. Genera predicciones de demanda a 30 días por línea y estación.

4. Dashboards Ejecutivos (Power BI):

Conectado directamente a Snowflake. Incluye cuatro vistas principales: demanda histórica, análisis de puntualidad, predicción a 30 días y KPIs ejecutivos con semáforos de estado.

Ventaja Competitiva:

Raillytics Light combina un stack tecnológico 100% del máster (PySpark + dbt + Delta Lake + Snowflake + Scikit-learn + Power BI) con datos reales y públicos disponibles desde el primer día, lo que garantiza la entrega completa en 4 meses con un equipo de 5 personas.

3. FUENTES DE DATOS

FUENTES DE DATOS

La plataforma se nutrirá de las siguientes fuentes públicas y gratuitas:

1. Renfe Open Data (fuente principal):

- Viajeros por estación: número de viajeros por estación y periodo (mensual/anual).
- Puntualidad por línea: porcentaje de trenes puntuales por línea y mes.
- Servicios por tipo de tren: AVE, Cercanías, Media Distancia, Larga Distancia.
- Horarios y frecuencias: programación de servicios por línea.
- Estaciones y líneas: catálogo de estaciones con geolocalización.

2. AEMET — Agencia Estatal de Meteorología (API pública gratuita):

- Temperatura media, precipitaciones y condiciones climáticas por provincia.
- Histórico diario por comunidad autónoma para correlación con puntualidad y demanda.

3. Festivos nacionales y autonómicos (BOE):

- Calendario oficial de festivos disponible en formato abierto.
- Variable clave para la estacionalidad del modelo predictivo.

4. INE — Instituto Nacional de Estadística:

- Datos de movilidad y población por provincias para enriquecimiento contextual.

Proceso de Recopilación y Procesamiento:

- Recopilación: descarga automática mediante Python (APIs REST, CSV públicos de Renfe y BOE).
- Validación de esquema: control de tipos, valores nulos y rangos en la capa Bronze.
- Limpieza y normalización: estandarización de nombres, fechas y códigos con PySpark en Silver.
- Enriquecimiento: cruce de viajeros con meteorología y festivos en Silver.
- Transformación al modelo dimensional: construcción de dimensiones y hechos en Gold con dbt.
- Almacenamiento final: carga incremental en Snowflake para consumo por Power BI.

4. TIPOS DE ANÁLISIS

TIPOS DE ANÁLISIS

Análisis Descriptivo:

- Objetivo: visualizar el comportamiento histórico de la demanda ferroviaria y la puntualidad.
- Componentes:
 - Evolución de viajeros por estación y línea a lo largo del tiempo.
 - Comparativa de puntualidad por línea, tipo de tren y comunidad autónoma.
 - Impacto de festivos y meteorología sobre la demanda y la puntualidad.
 - Rankings de estaciones por tráfico y líneas por nivel de servicio.
- Beneficio: proporciona a los gestores una visión completa del comportamiento del sistema ferroviario.

Análisis Predictivo:

- Objetivo: anticipar la demanda futura para mejorar la planificación de recursos.
- Componentes:
 - Predicción de viajeros a 30 días por estación y línea usando regresión con Scikit-learn.
 - Variables predictoras: historial de viajeros, día de la semana, festivos, temperatura, precipitaciones y estacionalidad.
 - Evaluación del modelo: RMSE, MAE y validación cruzada temporal (walk-forward validation).
- Beneficio: permite ajustar la oferta de servicios con antelación, reduciendo costes y mejorando la experiencia del viajero.

Análisis Prescriptivo:

- Objetivo: generar recomendaciones accionables a partir de los resultados predictivos.
- Componentes:
 - Alertas de picos de demanda previstos para planificación de recursos adicionales.
 - Identificación de líneas con riesgo de saturación en periodos festivos o eventos especiales.
 - Sugerencias de ajuste de frecuencias en rutas con demanda sistemáticamente desequilibrada.
- Beneficio: transforma las predicciones en decisiones concretas que optimizan la operación ferroviaria.

5. PROPUESTA DE ARQUITECTURA

PROPUESTA DE ARQUITECTURA


La arquitectura de Raillytics Light se estructura en torno a cinco componentes principales, siguiendo el patrón Medallion (Bronze → Silver → Gold) estándar en la industria de datos:

- 1. Capa Bronze — Ingesta y almacenamiento de datos en bruto (Python + Delta Lake)
- 2. Capa Silver — Limpieza, normalización y enriquecimiento (PySpark)
- 3. Capa Gold — Modelo dimensional y Data Warehouse (dbt + Snowflake)
- 4. Capa Analítica — Modelo predictivo de demanda (Scikit-learn)
- 5. Capa de Consumo — Dashboards ejecutivos (Power BI)

Nota: La arquitectura Medallion es la denominación estándar de la industria (acuñada por Databricks) para este patrón de tres capas de calidad de datos creciente: Bronze (datos brutos), Silver (datos limpios) y Gold (datos listos para consumo analítico).

PROPUESTA DE ARQUITECTURA

Diagrama de Componentes y Relaciones



PROPUESTA DE ARQUITECTURA

Capa Bronze — Ingesta y Almacenamiento de Datos en Bruto

Ingesta de Datos (Python):

- Scripts Python con scheduler que descargan automáticamente Renfe Open Data, API AEMET y festivos BOE.
- Validación de esquema en el punto de ingesta: tipos de datos, nulos y rangos aceptables.
- Control de idempotencia: cada ejecución detecta si los datos del periodo ya existen y evita duplicados.

Almacenamiento en Data Lake (Parquet + Delta Lake):

- Datos en bruto en formato Parquet particionado por fecha y fuente, sin ninguna transformación.
- Delta Lake aporta versionado y capacidad de rollback ante ingestas erróneas.
- Estructura: /bronze/renfe/ · /bronze/aemet/ · /bronze/festivos/ · /bronze/ine/

PROPUESTA DE ARQUITECTURA

Capa Silver — Limpieza, Normalización y Enriquecimiento

Preprocesamiento con PySpark:

- Limpieza: eliminación de duplicados, tratamiento de nulos y corrección de inconsistencias en nombres de estaciones y códigos de línea.
- Normalización: estandarización de formatos de fecha, unidades y codificación de variables categóricas.
- Enriquecimiento: cruce de datos de viajeros y puntualidad con variables meteorológicas de AEMET y festivos del BOE.

Almacenamiento en Delta Lake (capa Silver):

- Jobs PySpark que leen de Bronze, aplican transformaciones y escriben en Silver en formato Delta Lake.
- Particionado por año, mes y línea para optimizar consultas posteriores.
- Estructura: /silver/viajeros_enriquecidos/ · /silver/puntualidad_enriquecida/

PROPUESTA DE ARQUITECTURA

Capa Gold — Modelo Dimensional y Data Warehouse (Snowflake)

Transformación con dbt (Silver → Gold):

- Dimensiones: Dim_Estacion (código, nombre, comunidad, lat/lon), Dim_Linea (tipo de tren, origen, destino), Dim_Fecha (fecha, día semana, mes, trimestre, año, es_festivo, estación).
- Tablas de hechos: Fact_Viajeros (viajeros por estación, línea y fecha), Fact_Puntualidad (% puntualidad por línea, fecha y condición meteorológica).
- Tests de calidad dbt: unicidad de claves, integridad referencial y rangos de valores.

Almacenamiento en Snowflake:

- La capa Gold se carga de forma incremental en Snowflake mediante el conector dbt-snowflake.
- Snowflake proporciona capacidad de consulta analítica eficiente y conexión directa con Power BI.
- Trial gratuito de Snowflake (30 días) suficiente para la fase del TFM.

PROPUESTA DE ARQUITECTURA

Capa Analítica y de Consumo — Scikit-learn + Power BI

Modelo Predictivo de Demanda (Scikit-learn):

- Modelo de regresión (Random Forest Regressor como baseline) sobre Fact_Viajeros enriquecida.
- Features: viajeros históricos (lags temporales), día de la semana, es_festivo, temperatura_media, precipitacion, mes, tipo_tren.
- Evaluación: RMSE, MAE y R^2 con validación cruzada walk-forward (respeta temporalidad).
- Resultados de predicción cargados en Snowflake: Fact_Predicciones_Demanda.

Dashboards Ejecutivos (Power BI):

- Conectado directamente a Snowflake mediante conector nativo de Power BI.
- Dashboard 1 — Demanda ferroviaria: viajeros por estación, evolución temporal, comparativa por tipo de tren.
- Dashboard 2 — Puntualidad: retrasos por línea, impacto de meteorología, estaciones críticas.
- Dashboard 3 — Predicciones: forecast de demanda a 30 días, alertas de picos previstos.
- Dashboard 4 — KPIs ejecutivos: resumen de indicadores clave con semáforos de estado.

PROPUESTA DE ARQUITECTURA

Resumen del Flujo de Datos

1. Ingesta:

Scripts Python descargan automáticamente los datos de Renfe Open Data, AEMET y BOE. Todos los datos en bruto se almacenan en Bronze (Parquet + Delta Lake local).

2. Preprocesamiento y Limpieza:

PySpark limpia, normaliza y enriquece los datos combinando viajeros, meteorología y festivos. Los datos procesados se almacenan en Silver (Delta Lake).

3. Modelo Dimensional:

dbt transforma los datos de Silver en el esquema dimensional (dimensiones + hechos) y los carga de forma incremental en Snowflake (capa Gold).

4. Analítica Predictiva:

Scikit-learn entrena el modelo de predicción de demanda sobre los datos Gold. Las predicciones se almacenan como tabla adicional en Snowflake.

5. Visualización y Consumo:

Power BI se conecta directamente a Snowflake y presenta los dashboards ejecutivos de demanda, puntualidad, predicciones y KPIs al equipo de gestión.

Flujo completo:

Python (ingesta) → Bronze (Delta Lake) → PySpark (Silver) → dbt → Gold (Snowflake) → Scikit-learn (predicciones) → Power BI (dashboards)

6. CLIENTES / GRUPOS DE INTERÉS

CLIENTES / GRUPOS DE INTERÉS

Entre los posibles clientes se encuentran los siguientes:

- Renfe — Operador ferroviario nacional: para optimizar la planificación de recursos, ajustar frecuencias según demanda prevista y mejorar la puntualidad de los servicios.
- ADIF — Administrador de Infraestructuras Ferroviarias: para la gestión de capacidad de infraestructuras y la planificación de inversiones basada en datos de demanda real.
- Ministerio de Transportes, Movilidad y Agenda Urbana: para el diseño de políticas de movilidad sostenible y la evaluación del rendimiento de la red ferroviaria nacional.
- Comunidades Autónomas con competencias en transporte: para análisis de la demanda en redes de Cercanías y servicios de media distancia.

Los grupos de interés más destacados son:

- Viajeros y usuarios del transporte ferroviario: beneficiarios finales de la mejora operativa en términos de puntualidad, disponibilidad y calidad del servicio.
- Sindicatos y trabajadores del sector ferroviario: interesados en la optimización de la planificación de turnos y recursos basada en predicciones de demanda.
- Organismos de regulación del transporte: para el seguimiento y cumplimiento de los estándares de calidad del servicio ferroviario.
- Investigadores y analistas del sector transporte y movilidad: para estudios de movilidad, sostenibilidad y planificación urbana.
- Empresas de consultoría en datos y tecnología: como caso de referencia de implementación de una plataforma de datos ferroviarios con tecnología moderna.

7. KPIs

KPIs

Para medir el éxito de la plataforma y evaluar el progreso durante el desarrollo del TFM, se han definido los siguientes indicadores clave:

KPIs Técnicos:

- Completitud de datos: % de registros sin valores nulos en los datasets principales.
- Latencia del pipeline: Tiempo desde la captura del dato hasta su disponibilidad en SERVING.
- Precisión del modelo de predicción de demanda: F1-score y RMSE por línea y periodo.
- Precisión del modelo de puntualidad: F1-score, Precision y Recall.

KPIs de Negocio:

- Reducción estimada de incidencias por anticipación predictiva (%).
- Mejora de la tasa de puntualidad por línea en periodo analizado.
- Picos de demanda no previstos: número de días con demanda real muy superior a la prevista.
- Ahorro estimado en costes operativos por optimización de recursos.
- Número de dashboards activos y usuarios consultando la plataforma mensualmente.

8. ACTIVIDADES CLAVE

ACTIVIDADES CLAVE

- Exploración y validación de fuentes de datos (Semana 1-2): descarga, análisis exploratorio y validación de calidad de los datasets. Tarea distribuida entre los 5 miembros del equipo.
- Diseño de la arquitectura Medallion y modelo de datos (Semana 2-3): definición de capas Bronze/Silver/Gold, diseño del modelo dimensional y configuración del entorno técnico (Python, PySpark, dbt, Snowflake, Delta Lake).
- Implementación de la capa Bronze — Pipeline de ingesta (Semana 3-5): desarrollo de scripts Python de ingesta automatizada, validación de esquema y almacenamiento en Delta Lake particionado.
- Implementación de la capa Silver — Transformaciones PySpark (Semana 5-8): desarrollo de jobs PySpark de limpieza, normalización y enriquecimiento. Tests unitarios de las transformaciones.
- Implementación de la capa Gold con dbt y carga en Snowflake (Semana 8-10): desarrollo de modelos dbt para el esquema dimensional, configuración de la conexión dbt-Snowflake y carga incremental.
- Entrenamiento y validación del modelo predictivo con Scikit-learn (Semana 10-13): feature engineering, entrenamiento del modelo, validación cruzada temporal y carga de predicciones en Snowflake.
- Desarrollo de dashboards en Power BI (Semana 13-15): creación de los cuatro dashboards conectados a Snowflake, con los 5 miembros revisando y validando los resultados.
- Documentación técnica y preparación de la defensa (Semana 15-16): redacción de la memoria del TFM, documentación de la arquitectura y preparación de la presentación para el tribunal. Tarea conjunta del equipo de 5 personas.

9. RECURSOS CLAVE

RECURSOS CLAVE

Recursos Técnicos de Infraestructura y Procesamiento de Datos:

- Almacenamiento local (Data Lake Bronze/Silver):
 - Descripción: sistema de ficheros local con Delta Lake sobre Parquet para las capas Bronze y Silver. Sin coste durante el TFM.
 - Justificación: los datos de Renfe Open Data tienen un volumen manejable localmente (< 5 GB), eliminando la necesidad de infraestructura cloud en las fases de ingesta y transformación.
- Snowflake — Data Warehouse (capa Gold):
 - Descripción: plataforma cloud de Data Warehouse para almacenar y consultar la capa Gold. Se utiliza el trial gratuito de 30 días.
 - Justificación: herramienta clave del máster, conectividad nativa con Power BI y dbt, y arquitectura serverless sin gestión de infraestructura.
- Pipeline de transformación con dbt:
 - Descripción: herramienta de transformación SQL que gestiona los modelos dimensionales, tests de calidad y documentación del linaje de datos.
 - Justificación: estándar de la industria para la capa de transformación, trabajado en el máster.

RECURSOS CLAVE

Herramientas de Procesamiento de Datos y Análisis:

- Motor de Procesamiento de Datos (PySpark):
 - Descripción: Apache Spark en Python para el procesamiento distribuido en las capas Bronze y Silver.
 - Justificación: herramienta central de procesamiento del máster, permite escalar si los datos crecen.
- Data Warehouse (Snowflake):
 - Descripción: plataforma cloud para almacenar la capa Gold y servirla a Power BI.
 - Justificación: arquitectura serverless, conector nativo con Power BI y dbt. Herramienta del máster.
- Herramientas de Machine Learning (Scikit-learn):
 - Descripción: librería Python estándar para el entrenamiento del modelo predictivo de demanda ferroviaria.
 - Justificación: librería de ML más utilizada en el sector, trabajada en el módulo de ML del máster.

RECURSOS CLAVE

Recursos Humanos — Equipo del TFM (5 personas, Grupo 3):

- Data Engineer (Pipeline de Ingesta + Bronze):
 - Responsabilidades: diseño e implementación de los scripts Python de ingesta automatizada, validación de esquema y almacenamiento en Delta Lake (capa Bronze). Control de versiones con GitHub.
- Data Engineer (Transformaciones PySpark + Silver):
 - Responsabilidades: desarrollo de los jobs PySpark de limpieza, normalización y enriquecimiento de datos. Construcción y mantenimiento de la capa Silver con Delta Lake.
- Analytics Engineer (dbt + Gold + Snowflake):
 - Responsabilidades: desarrollo de los modelos dbt para el esquema dimensional (dimensiones y hechos), configuración de la conexión dbt-Snowflake y tests de calidad de datos. Mantenimiento de la capa Gold.
- Data Scientist (Modelo Predictivo Scikit-learn):
 - Responsabilidades: exploración de datos, feature engineering, entrenamiento y validación del modelo predictivo de demanda con Scikit-learn. Evaluación de métricas (RMSE, MAE, R^2) y carga de predicciones en Snowflake.
- Data Analyst (Dashboards Power BI + Documentación):
 - Responsabilidades: diseño y desarrollo de los cuatro dashboards ejecutivos en Power BI conectados a Snowflake. Coordinación de la documentación técnica y preparación de la presentación para el tribunal.

Distribución de Tareas por Mes:

Mes 1:

- Implementar la capa Bronze (ingesta Python + Delta Lake).
- Diseña el modelo dimensional.
- Realizan la exploración de datos y análisis inicial.

Mes 2:

- Implementar Silver con PySpark
- Implementar la capa Gold con dbt + Snowflake.
- Realizar test de validacion de calidad.

Mes 3:

- Entrenar el modelo predictivo con Scikit-learn.
- Desarrollar el dashboards en Power BI.
- Revisar y validar resultados.

Mes 4:

- Refinamiento del modelo y dashboards.
- Preparar la memoria del TFM y la defensa ante el tribunal.

10. COSTES DE IMPLEMENTACIÓN

COSTES DE IMPLEMENTACIÓN

1. Coste durante el TFM (4 meses) :

Al tratarse de un proyecto académico de Máster, todos los costes de personal y herramientas son cero. Las 5 personas del equipo trabajan como parte de su TFM y todas las herramientas utilizadas son gratuitas o disponen de versión trial suficiente:

- Python, PySpark, dbt Core, Delta Lake, Scikit-learn y GitHub: completamente gratuitos (open source).
- Snowflake: trial gratuito de 30 días con créditos suficientes para las cargas del TFM.
- Renfe Open Data, AEMET API, festivos BOE, INE: datos públicos y gratuitos.
- Power BI Desktop: versión gratuita suficiente para el desarrollo y la defensa del TFM.

2. Estimación de coste si se desplegara en producción real:

Categoría	Fase TFM (€)	Producción (€/mes)
Personal (5 estudiantes — TFM académico, sin coste)	0	3.500 – 5.000
Snowflake (trial gratuito 30 días, suficiente para el TFM)	0	400 – 800
Google Cloud Storage / almacenamiento local Parquet + Delta Lake	0	100 – 300
PySpark, dbt Core, Delta Lake, Scikit-learn, GitHub (open source)	0	0
Power BI Desktop (versión gratuita para desarrollo y defensa)	0	10 – 20
Renfe Open Data, AEMET API, festivos BOE, INE (datos públicos)	0	0
Licencias adicionales y herramientas opcionales en producción	0	200 – 500
TOTAL	0 €	~4.200 – 6.600 €/mes

3. Consideraciones adicionales:

- El coste de producción puede reducirse significativamente usando DuckDB en lugar de Snowflake para entornos con menor volumen de datos.
- La arquitectura local con Delta Lake elimina la dependencia de servicios cloud durante el desarrollo, minimizando el riesgo de costes inesperados.
- En caso de necesitar ampliar el trial de Snowflake, existe la opción de crear una cuenta nueva sin coste adicional.

11. RIESGOS

RIESGOS

Identificar y gestionar los riesgos es esencial para garantizar la entrega completa del proyecto en el plazo de 4 meses con el equipo de 5 personas. A continuación se presentan los principales riesgos y las estrategias de mitigación:

Calidad e Irregularidad de Renfe Open Data:

Los datasets públicos de Renfe pueden presentar series temporales incompletas, cambios de formato sin previo aviso o periodos sin actualizar. Mitigación: validación de esquema en la ingesta, uso de múltiples fuentes de respaldo y acotación del alcance a los datasets más estables.

Limitación del Trial de Snowflake (30 días):

El periodo gratuito puede ser insuficiente si el proyecto se alarga. Mitigación: planificar el uso de Snowflake en la fase final del proyecto (mes 2-3), con DuckDB como alternativa local totalmente compatible con dbt.

Precisión del Modelo Predictivo:

Los datos históricos de viajeros pueden tener poca variabilidad o estar afectados por eventos atípicos (pandemia, huelgas). Mitigación: análisis exploratorio previo, limpieza de periodos atípicos y establecimiento de métricas mínimas aceptables antes del entrenamiento.

Coordinación del Equipo de 5 Personas:

La distribución de tareas entre 5 personas requiere una coordinación efectiva para evitar bloqueos y dependencias entre capas. Mitigación: reuniones semanales de seguimiento, uso de GitHub para control de versiones y gestión de ramas por capa (Bronze, Silver, Gold, ML, BI).

Tiempo Limitado (4 meses):

El alcance debe estar bien controlado para garantizar la entrega completa. Mitigación: alcance acotado con un único modelo predictivo y cuatro dashboards bien definidos. Cada miembro del equipo tiene un entregable claro y medible.

12. BENEFICIOS / IMPACTOS

BENEFICIOS / IMPACTOS

Los beneficios e impactos del proyecto se dividen entre los distintos grupos de interés:

- Beneficios para Renfe y ADIF:
 - Optimización de recursos: ajuste proactivo de la oferta de servicios en función de la demanda prevista, reduciendo el coste de trenes infrautilizados.
 - Mejora de la puntualidad: identificación de los factores externos que más impactan en los retrasos, permitiendo medidas preventivas.
 - Visibilidad ejecutiva: dashboards actualizados con KPIs clave del sistema ferroviario, accesibles desde Power BI sin informes manuales.
- Beneficios para los viajeros:
 - Servicio más fiable: la mejor planificación basada en datos reduce las cancelaciones y mejora la puntualidad.
 - Mayor disponibilidad de plazas en periodos de alta demanda gracias a la anticipación de picos.
- Beneficios para el equipo del TFM (5 personas):
 - Demostración de un stack tecnológico completo y profesional: PySpark + dbt + Snowflake + Scikit-learn + Power BI.
 - Proyecto con datos reales y resultados verificables, de mayor credibilidad ante el tribunal que proyectos con datos sintéticos.
 - Refuerzo del perfil profesional como Data Engineers con experiencia en arquitecturas Medallion, transformaciones dbt y análisis predictivo aplicado.
 - Cada miembro del equipo puede demostrar una especialidad clara: ingesta, transformación, modelado dimensional, ML y visualización.
- Impactos sociales y medioambientales:
 - Apoyo a la movilidad sostenible: un transporte ferroviario más eficiente y fiable fomenta el trasvase modal desde el coche y el avión.
 - Contribución a la reducción de emisiones de CO2: la optimización de servicios reduce el número de trenes vacíos circulando.
 - Mejora de la planificación de movilidad urbana integrada en ciudades españolas.
- Impacto como producto de datos escalable:
 - La arquitectura Medallion y los modelos dbt son reutilizables para otras líneas, modos de transporte o países con sistemas ferroviarios similares.
 - La plataforma puede ampliarse con nuevas fuentes o modelos sin modificar la arquitectura base.